Université Abdelmalek Essaâdi
École nationale des sciences appliquées
d'Al Hoceima

Fliére: Transformation Digitale et IA

Module: Deep Learning

Compte Rendu:

TP1(SLP)

Réalisé par:
Amal Dadda Amami

Encadré par:
Prof.M.Cherradi

Année Universitaire:
2025/2026

Introduction

Ce compte rendu presente les resultats du TP N°1 portant sur l'implementation du Perceptron Monocouche .

2-Lien Colab:

https://colab.research.google.com/drive/1rfZgq3D3MPXgBwYjesTOgy_Dfi1oHNDl#scrollTo=8Vc2Ip-36m1i

Exercice 1 : Classification des portes logiques AND et OR

Entrainer un Perceptron sur les fonctions logiques AND et OR, qui sont toutes deux lineairement separables.

1- Ensembles de données

Les tables de verite pour les deux portes logiques :

X1	X2	AND	OR
0	0	0	0
0	1	0	1
1	0	0	1
1	1	1	1

2- Resultats et analyse

Le Perceptron apprend parfaitement AND et OR car elles sont lineairement separables. Les trois methodes convergent vers 100% de precision. La porte XOR, non lineairement separable, ne pourrait pas etre apprise par un SLP.

Exercice 2 : Classification binaire - Iris Setosa

Classer Iris Setosa (classe 0) contre les deux autres especes, en utilisant les 4 features du dataset Iris (150 echantillons). Division 80/20.

1- Resultats

Methode	Accuracy
From scratch	100%
Scikit-learn	100%
Keras (100 epochs, sgd)	~76.7%

2- Analyse

From scratch et sklearn atteignent 100% car Iris Setosa est parfaitement separable lineairement des autres classes. Le modele Keras (76.7%) est moins performant : il utilise uniquement 2 features et souffre d'une convergence incomplete avec SGD sur peu de donnees. Avec les 4 features et plus d'epochs, les performances seraient similaires.

Exercice 3 : Regression lineaire avec le Perceptron

Apprendre la fonction y = 2x + 1 avec 50 points sur [0, 10]. Division 80/20. Evaluation par MSE.

1- Resultats

Methode	MSE	Observation
From scratch	0.00000000000335	Quasi-parfait, convergence excellente
Scikit-learn	0	Exact (solution analytique)
Keras (100 epochs)	0.0032	Bonne approximation, convergence partielle

2- Analyse

Le modéle from scratch (lr=0.01, epochs=100) et sklearn atteignent une MSE quasi-nulle sur une fonction parfaitement lineaire. Keras, utilisant SGD par mini-batches, obtient 0.0032 ;échs).

Exercice 4 : Perceptron sur MNIST

Application du Perceptron sur le dataset MNIST (images 28x28 = 784 pixels). Tache binaire : detecter le chiffre 0 vs tous les autres. Sous-ensemble : 2000 images d'entrainement, 500 de test.

1- Preparation

Images aplaties en vecteurs de 784 dimensions, normalisees entre 0 et 1. Labels binarises : 1 si chiffre=0, 0 sinon.

2- Resultats

Methode	Accuracy sur 500 tests
From scratch	98.40%
Scikit-learn	98.80%
Keras	97.80%

3- Limitations

Les trois methodes donnent d'excellents resultats sur cette tache binaire simple (détéction du 0). Cependant, pour une classification des 10 chiffres, le SLP serait limite par sa frontierre lineaire dans 784 dimensions. Un CNN atteindrait >99% sur la classification complete. La taille du sous-ensemble (2000 exemples) suffit ici car la tache est binaire.

Exercice 5 : Segmentation avec make_blobs

1- Generation et pretraitement

300 points bidimensionnels, 3 centres, random_state=42. Normalisation par StandardScaler. Le Perceptron est entraine uniquement sur les clusters 0 et 1 (classification binaire).

2- Implementation

From scratch : w=zeros(2), b=0, lr=0.1, epochs=50, activation par seuil. Frontiere de decision visualisée comme droite rouge.
KMeans : éxtension a 3 clusters avec sklearn.cluster.KMeans(n_clusters=3), sans etiquettes.

3- Analyse comparative

Critere	Perceptron (scratch)	Scikit-learn / Keras	KMeans
Type	Supervisé	Supervisé	Non supervisé
Etiquettes ?	Oui	Oui	Non
Frontieres	Linéaires	Linéaires	Centroide
Multi-classes	Non (binaire)	Oui	Oui (natif)
Qualité	Excellente	Excellente	Excellente

4- Perceptron vs KMeans

Le Perceptron (méthode supervisee) nécessite des étiquettes pour apprendre une frontière lineaire entre deux classes. KMeans groupe les points par proximite euclidienne aux centroides sans connaitre les vraies classes, et gere nativement les 3 clusters. Sur des données bien séparées comme make_blobs, les deux approches produisent d'excellents resultats.

Conclusion generale

Exercice	From Scratch	Scikit-learn	Keras
Ex1 - AND/OR	100%	100%	100%
Ex2 - Iris Setosa	100%	100%	76.70%
Ex3 - Regression	MSE 3.35e-12	MSE 0.0	MSE 0.0032
Ex4 - MNIST (binaire)	98.40%	98.80%	97.80%
Ex5 - Blobs	Excellente	Excellente	Excellente

Le Perceptron monocouche apprend efficacement tous les problémes lineairement separables. L'implementation from scratch permet de comprendre la regle de mise a jour des poids. Scikit-learn offre la solution la plus simple et précise. Keras est le plus flexible pour évoluer vers des architectures profondes. Les limites du SLP apparaissent sur des tâches non linéaires ou multiclasses compléxes.